

AI Infrastructure

GPU clusters & MLOps

Xưởng động cơ cho tiềm kích hạng nặng: hạ tầng GPU/accelerator, cluster huấn luyện, MLOps và phục vụ LLM ở quy mô sản xuất — đủ lực và đủ ổn định.

Bảng mô tả dịch vụ
 Service description

Mã dịch vụ Service code	NS-GPU
Nhóm dịch vụ Service group	Hạ tầng AI
Phạm vi Scope	Cluster GPU, scheduler, MLOps, model serving, tối ưu suy luận
Đối tượng Target customers	Tổ chức huấn luyện hoặc phục vụ mô hình lớn, bao gồm LLM
Mô hình hợp tác Engagement models	Dự án dựng hạ tầng · vận hành cluster theo tháng
Cam kết Commitments	SLA theo hợp đồng · cam kết mức sẵn sàng cluster và thông lượng

SẢN PHẨM BÀN GIAO · DELIVERABLES

- ✓

Thiết kế và triển khai cluster GPU
- ✓

MLOps pipeline từ huấn luyện đến phát hành mô hình
- ✓

Lớp phục vụ mô hình có giám sát
- ✓

Báo cáo hiệu suất sử dụng GPU

KẾT QUẢ KỲ VỌNG · OUTCOMES

- Tận dụng GPU hiệu quả hơn, giảm thời gian chờ
- Mô hình đưa vào sản xuất theo quy trình chuẩn
- Chi phí suy luận trên mỗi yêu cầu giảm

■ **Hạng mục công việc theo giai đoạn** Consult → Deploy → Operate → Optimize

01

Tư vấn / Consult

- Xác định workload và nhu cầu tính toán
- Thiết kế cluster GPU
- So sánh phương án on-prem / cloud
- Dự toán TCO

02

Triển khai / Deploy

- Dựng cluster & scheduler
- Cấu hình mạng tốc độ cao và lưu trữ
- Triển khai MLOps pipeline
- Dựng lớp model serving

03

Vận hành / Operate

- Vận hành cluster 24/7
- Quản trị hạn mức GPU theo nhóm
- Theo dõi hiệu suất và nhiệt độ
- Bảo trì và cập nhật driver

04

Tối ưu / Optimize

- Tối ưu sử dụng GPU
- Quantization & tối ưu suy luận
- Autoscaling theo tải
- Giảm chi phí trên mỗi yêu cầu

CÔNG NGHỆ SỬ DỤNG · TECHNOLOGY STACK

NVIDIA GPU

Kubernetes

Kubeflow

MLflow

Ray

Slurm

vLLM

Triton Inference Server

GPU Operator

Bắt đầu với AI Infrastructure bằng một buổi khảo sát hiện trạng.

Start with a current-state assessment.

Điện thoại

+84 973 391 388

Email

dungpv30@fpt.com.vn